



Actividad 2.1

- Pipeline de Datos – Ingesta de datos automatizada

A black and white photograph of a man in a suit standing in a modern office, holding a tablet and smiling. The office has glass partitions and modern furniture. A blue square is in the top right corner.

01

**Objetivo de
la actividad**

• Objetivo de la actividad

El propósito central de esta actividad es que los estudiantes comprendan el concepto de pipeline de datos como una arquitectura secuencial y modular que permite la recolección, transformación, validación y almacenamiento eficiente de datos.

En este contexto, se espera que los estudiantes identifiquen el rol que cumple la etapa de ingesta dentro del pipeline y reconozcan su relevancia para garantizar la trazabilidad, integridad y estandarización inicial de los datos.

Asimismo, se busca que apliquen principios fundamentales de DataOps mediante la implementación automatizada de una ingesta controlada desde una fuente de origen hacia un entorno estructurado, sentando así las bases para las siguientes fases del flujo de trabajo de datos.



02

Introducción y desarrollo

Introducción

Esta primera actividad marca el inicio del desarrollo práctico de un pipeline de datos, permitiendo a los estudiantes aproximarse a una visión integral del ciclo de vida de los datos.

Se abordarán los fundamentos conceptuales de un pipeline y su importancia para asegurar la eficiencia, repetibilidad y calidad en proyectos de análisis de datos. Dentro de este marco, se profundizará en la etapa de ingesta como el punto de partida técnico, responsable de capturar los datos desde su fuente original y depositarlos en una estructura organizada que permita su posterior procesamiento.

Además, se introducirá la lógica de organización del repositorio técnico del proyecto, así como algunas nociones básicas de versionamiento, automatización y buenas prácticas en entornos colaborativos basados en principios de DataOps

¿Qué es un pipeline de datos?

Un pipeline de datos es una secuencia de procesos automatizados que permite mover, transformar y almacenar datos desde su origen hasta su destino final.

Su objetivo es garantizar que los datos fluyan de manera ordenada, íntegra y trazable entre etapas, asegurando su calidad para el análisis y la toma de decisiones.

Un buen diseño de pipeline se basa en principios de DataOps, promoviendo la colaboración, la eficiencia operativa y el control de versiones en equipos multidisciplinarios.

Pipeline de datos

Etapas comunes de un pipeline de datos:



Pipeline de datos

Ubicación dentro del pipeline de datos:

- **Ingesta de datos** ← (Actividad actual)
- Limpieza y transformación de datos
- Validación estructural y semántica
- Carga a base de datos

Esta actividad se enfoca en capturar y trasladar datos desde una o más fuentes hacia un sistema de almacenamiento centralizado.

Ingesta de datos


La ingesta de datos es el proceso de capturar y trasladar datos desde una o más fuentes hacia un sistema de almacenamiento centralizado, donde podrán ser procesados, transformados y analizados posteriormente.

Esta etapa es el punto de entrada del pipeline de datos y puede implicar métodos en tiempo real (streaming) o por lotes (batch), dependiendo de los requerimientos del sistema.

Una ingesta bien diseñada garantiza la disponibilidad oportuna de los datos, asegura su integridad desde el origen y sienta las bases para una trazabilidad confiable a lo largo del ciclo de vida del dato.

Ingesta de datos

Flujo técnico de una ingesta



Script de ejemplo

```
Ingesta.py
1  import shutil
2
3  origen = "origen/historial_ventas.csv"
4  destino = "data/raw/historial_ventas.csv"
5
6  shutil.copy(origen, destino)
7  print("Archivo copiado exitosamente.")
```

Tipos de Ingesta

1. Ingesta por lotes (Batch Ingestion):

Los datos se recolectan y se transfieren en bloques o grupos en intervalos definidos (por ejemplo, cada hora o al final del día). Es común en procesos periódicos y cuando no se requiere inmediatez.

2. Ingesta en tiempo real (Real-Time Ingestion):

Los datos se capturan y se transfieren al sistema de destino de forma continua y casi instantánea, permitiendo su procesamiento inmediato. Es usada en casos donde la inmediatez es crítica (monitoring, IoT, etc.).

3. Ingesta incremental (Incremental Ingestion):

Solo se transfieren los nuevos datos o aquellos que han cambiado desde la última ingesta, optimizando el rendimiento y reduciendo carga de red y almacenamiento.

4. Ingesta por streaming:

Variante de la ingesta en tiempo real, en la que los datos fluyen como un continuo desde la fuente y se procesan al vuelo, generalmente mediante herramientas como Apache Kafka o AWS Kinesis.

5. Ingesta manual:

Los datos son cargados manualmente por un usuario, típicamente a través de archivos como Excel o CSV. Es menos eficiente y más propensa a errores, pero aún utilizada en escenarios de baja frecuencia o validación inicial.

6. Ingesta programada (Scheduled Ingestion):

Similar a la por lotes, pero con ejecuciones controladas por un planificador o cron job, útil para mantener sincronización regular con fuentes externas.

A black and white photograph of a woman in a server room. She is standing in a narrow aisle between rows of server racks. She is holding a tablet in her left hand and touching a small screen or button on the front of a server rack with her right hand. The server racks are filled with various electronic components and fans. The room is dimly lit, with bright light coming from a window or opening at the far end of the aisle. The overall atmosphere is professional and technical.

03

Trabajo Autónomo

Actividad Sugerida:

Cada estudiante deberá desarrollar individualmente un script funcional de ingesta de datos que permita obtener información desde una fuente estructurada (como un archivo CSV o una API pública), organizarla y almacenarla como parte del flujo inicial de un Pipeline de Datos.

El trabajo deberá cumplir con los siguientes criterios:

- Obtener correctamente los datos desde la fuente estructurada seleccionada.
- Implementar la automatización del proceso de obtención y almacenamiento.

Trabajo Autónomo

- Incluir trazabilidad básica mediante logging del proceso (inicio, éxito/error, cantidad de registros procesados, etc.).
- Utilizar control de versiones con Git, asegurando el uso adecuado de commits y estructura del repositorio.
- Subir el proyecto a GitHub incluyendo un README breve que describa el objetivo del script y cómo ejecutarlo.

Este trabajo permitirá poner en práctica los conceptos abordados en clases respecto a automatización, modularidad básica y control de versiones, dando inicio al pipeline de procesamiento de datos.

04

Cierre



Cierre y logros alcanzados

Con esta actividad, diste el primer paso en la construcción técnica de un pipeline de datos, comprendiendo cómo se inicia y se estructura el flujo completo desde la fuente de datos hasta su destino.

¿Qué lograste hoy?

- Comprendiste el concepto de pipeline de datos y su importancia en los procesos de integración y análisis.
- Implementaste la **etapa de ingesta**, automatizando la extracción y carga inicial del dataset base.

¿Qué lograste hoy?

- Estructuraste tu **repositorio técnico**, siguiendo buenas prácticas de organización.
- Aplicaste **control de versiones** mediante Git, asegurando trazabilidad y orden en tu trabajo.
- Documentaste adecuadamente esta primera etapa en el archivo README.md facilitando la comprensión del proceso por parte de otros usuarios o equipos.

¿Qué viene después?

EA2 – Actividad 2: Limpieza y transformación del dataset

¿Qué harás en la próxima sesión?:

- Aplicarás reglas de limpieza a los datos ingresados.
- Identificarás y eliminarás inconsistencias.
- Transformarás las columnas clave para el análisis posterior.
- Dejarás listo el dataset para validación estructural.

Recuerda: Desde ahora, cada paso técnico que implementes se conecta directamente con el modelo predictivo del caso que vas a elegir.

DuocUC[®]

CERCANÍA. LIDERAZGO. FUTURO.

duoc.cl

7 AÑOS
ACREDITADO



DESDE AGOSTO 2017 HASTA AGOSTO 2024.
DOCENCIA DE PREGRADO. GESTIÓN
INSTITUCIONAL. VINCULACIÓN CON EL MEDIO.