



Actividad 2.3

- Pipeline de Datos – Validación estructural y semántica de datos

A black and white photograph of a man in a suit standing in a modern office, holding a tablet and smiling. The office has glass partitions and modern furniture. A blue square is in the top right corner.

01

**Objetivo de
la actividad**

• **Objetivo de la actividad**

En esta actividad aplicarás técnicas de validación de datos para asegurar que tu dataset transformado cumpla con los requerimientos técnicos y lógicos definidos por el proyecto.

Aprenderás a automatizar validaciones estructurales (tipos de datos, formatos, rangos) y semánticas (consistencia interna y reglas de negocio), fortaleciendo así la calidad e integridad del flujo de datos.



02

Introducción y desarrollo

Una vez que los datos han sido limpiados y transformados, es fundamental confirmar que cumplan con la estructura esperada y las reglas definidas para su interpretación.

Esta etapa permite identificar errores que podrían comprometer el análisis o modelado posterior.

Implementarás un sistema de validación reproducible, documentado y versionado, en línea con buenas prácticas de DataOps.

Ubicación dentro del pipeline de datos:

- Ingesta de datos
- Limpieza y transformación de datos
- **Validación estructural y semántica ← (Actividad actual)**
- Carga a base de datos

Esta actividad se enfoca en limpiar, estandarizar y transformar datos, permitiendo que estén listos para ser validados y cargados de forma confiable.

¿Qué es la Validación Estructural?

La Validación Estructural es el proceso mediante el cual se verifica que los datos cumplan con los requerimientos técnicos establecidos para su correcta interpretación y procesamiento por sistemas informáticos.

Este tipo de validación asegura que:

- Cada columna tenga el **tipo de dato correcto** (por ejemplo, fechas, enteros, texto).
- Se respeten formatos específicos como fechas en YYYY-MM-DD o correos electrónicos con estructura válida.

Validación Estructural

- Los valores se mantengan dentro de rangos aceptables (por ejemplo, que una edad esté entre 0 y 120).

Esta validación actúa como una primera barrera para prevenir errores que detendrían procesos posteriores de análisis, transformación o carga en bases de datos.

Técnicas utilizadas:

- Castings y conversiones explícitas. Por ej: `int(x)` o `pd.to_datetime()` en Pandas.
- Validaciones con expresiones regulares (Regex) para formatos.
- Librerías como `pandera`, `pydantic`, `cerberus` o `Great Expectations` que permiten definir esquemas estructurales para datasets.

¿Qué es la Validación Semántica?

La Validación Semántica es el proceso mediante el cual se evalúa si los datos tienen sentido dentro del contexto del negocio o dominio de la aplicación.

A diferencia de la validación estructural, aquí no basta con que el dato esté en el formato correcto: debe además **cumplir con reglas lógicas, relaciones condicionales o coherencia entre múltiples campos.**

Validación Semántica

Por ejemplo:

- Si el **campo estado = “finalizado”**, entonces **fecha_fin no puede ser nulo**.
- Si **tipo_cliente = “empresa”**, entonces **debe existir un Rut representante**.
- Un **porcentaje_descuento no puede superar el 100%**.

Esta validación garantiza la consistencia y validez lógica de los datos, incluso cuando parecen válidos desde el punto de vista técnico.

Técnicas utilizadas:

- Reglas condicionales en código (if/else).
- Validaciones cruzadas entre columnas.
- Aplicación de reglas de negocio definidas previamente por el equipo funcional o experto del dominio.
- Testing con conjuntos de datos controlados (unit testing de lógica de validación).
- Uso de librerías como Greats Expectations para reglas más avanzadas y testeo automatizado de la lógica semántica.

Validación Estructural y Semántica

Recomendaciones metodológicas

- Identificar y documentar reglas técnicas y de negocio.
- Usar funciones separadas para validaciones estructurales y semánticas.
- Registrar errores y advertencias en logs.
- Separar datos válidos de inválidos.
- No modificar los archivos de entrada directamente.
- Usar Git para versionar y explicar cada mejora en validaciones.

A black and white photograph of a woman in a server room. She is standing in a narrow aisle between rows of server racks. She is holding a tablet in her left hand and touching a small screen or button on the front of a server rack with her right hand. The server racks are filled with various components, including fans and cables. The room is dimly lit, with bright light coming from the ceiling. The overall atmosphere is professional and technical.

03

Trabajo Autónomo

Actividad Sugerida:

Cada estudiante deberá implementar un script de validación sobre un dataset con errores intencionados.

El script deberá incluir:

- Al menos 3 validaciones estructurales y 2 semánticas.
- Separación de registros válidos/erróneos.
- Logs explicativos.

Se espera que el código esté modularizado, versionado en GitHub y acompañado por un documento README.md que explique el proceso y justifique cada decisión técnica tomada.

04

Cierre



Cierre y logros alcanzados

Con esta actividad, has profundizado en tres etapas fundamentales del pipeline de datos: **la validación estructural y semántica**.

Lograste identificar reglas técnicas y semánticas, automatizar validaciones para asegurar la integridad de los datos y preparar datos confiables para su uso en modelos o reportes.

¿Qué viene después?

EA2 – Actividad 4: Pipeline de Datos – Carga de datos a base de datos

¿Qué harás en la próxima sesión?:

- Conectarás tu pipeline a una base de datos.
- Implementarás scripts para cargar datos validados.
- Asegurarás integridad referencial y eficiencia en el almacenamiento.
- Registrarás errores y anomalías detectadas.
- Dejarás el dataset en una base de datos para ser usado por el modelo predictivo final.

Recuerda: Esta etapa asegura que los datos que pasarán a modelado cumplen con todos los requisitos técnicos y de calidad requeridos.

DuocUC[®]

CERCANÍA. LIDERAZGO. FUTURO.

duoc.cl

7 AÑOS
ACREDITADO



DESDE AGOSTO 2017 HASTA AGOSTO 2024.
DOCENCIA DE PREGRADO. GESTIÓN
INSTITUCIONAL. VINCULACIÓN CON EL MEDIO.