

De Datos Crudos a Predicciones: El Camino de la Preparación de Datos

Sección 1: El Punto de Partida - Datos Crudos

El Estado Crudo de la Información

Los datos iniciales suelen presentarse con problemas críticos como datos faltantes, registros duplicados, inconsistencias y valores atípicos que deben ser resueltos.




El Secreto: Datos de Calidad

Entrenar un modelo con datos preparados aumenta significativamente la probabilidad de obtener mejores predicciones.

Sección 2: Identificación y Clasificación


Variable Objetivo (Dependiente)

La variable objetivo es la que el modelo predecirá.




Variables Predictoras (Independientes)

El resto son las variables predictoras que se determinan mediante técnicas como la correlación.




Tipos de Variables

Los datos pueden ser cualitativos o cuantitativos; esta naturaleza define el tipo de problema a resolver.



Regresión

Si la variable objetivo es continua, se usa un modelo de Regresión.



Clasificación

Si es discreta o cualitativa, se usa un modelo de Clasificación.

Sección 3: El Proceso de Transformación

Limpieza y Estandarización

Implica corregir errores, estandarizar o normalizar variables cuantitativas y codificar las variables cualitativas para que el modelo las entienda.




Ingeniería de Características

Consiste en usar la creatividad técnica para obtener nuevas variables a partir de las ya existentes para enriquecer el modelo.

Sección 4: Entrenamiento y Validación




80% Entrenamiento (Train)



La Regla del 80/20

El set de datos preparado se divide típicamente en un 80% para entrenamiento y un 20% para pruebas.

20% Pruebas (Test)



Evaluación Final

Tras el entrenamiento, se realizan predicciones con los datos de test y se evalúan los resultados usando métricas asociadas al tipo de problema (regresión o clasificación).